

Neizrazito, evolucijsko i neuro računarstvo: 6. domaća zadaca - izvještaj

Krešimir Topolovec 0036485747

Siječanj 2020.

1 ANFIS

Koristimo Neuro-Fuzzy sustav ANFIS (engl. Adaptive Neuro-Fuzzy Inference System) koji pripada pod hibridni pristup kombiniranja neuronskih mreža i sustava neizrazitog zaključivanja. Kod ovog sustava neuronska mreža je istovremeno i sustav neizrazitog zaključivanja. U ovoj vježbi koristimo primjer takvog sustava koji ima 2 ulaza i 1 izlaz odnosno obavlja preslikavanje $R^2 \rightarrow R$ i koristi zaključivanje tipa 3 (metoda Takagi-Sugeno-Kang). Prikaz takvog sustava je na slijedećoj slici:




Figure 1: ANFIS sa 2 ulaza i 1 izlazom koji koristi TSK zaključivanje

ANFIS obavlja preslikavanje koristeći pravila oblika:

$$R_i : \text{AKO } x \text{ je } A_i \text{ I } y \text{ je } B_i \text{ ONDA } z_i = p_i x + q_i y + r_i, i = 1..m$$

Neuroni u prvom sloju na slici 1 modeliraju neizrazite skupove. Njihova prijenosna funkcija (a time i funkcija pripadnosti koju koristi sustav ANFIS) je:

$$A_i(x) \equiv \mu_{A_i}(x) = \frac{1}{1 + e^{b_i(x-a_i)}}$$

$$B_i(y) \equiv \mu_{B_i}(y) = \frac{1}{1 + e^{d_i(y-c_i)}}$$

Neuroni drugo sloja računaju konjukciju pravila (ukupnu "jakost" i-tog pravila) pa koristimo t-normu. U zadatku je kao t-norma definiran produkt:

$$\mu_{A_i \cap B_i}(x) = \mu_{A_i}(x) \cdot \mu_{B_i}(x)$$

Izraz μ_{A_i} označimo s α_i , te μ_{B_i} s β_i , jakost pravila i tada je:

$$w_i = \alpha_i \cdot \beta_i \quad (1)$$

Jakost svakog pravila se skalira(dijeli) sumom jakosti ostalih pravila, to obavlja sloj 3. Konsekvent svakog pravila koji je definiran kao funkcija z_i (na slici f_i):

$$z_i = p_i x + q_i y + r_i, i = 1..m \quad (2)$$

množi se sa skaliranom težinom, ovo računa 4. sloj mreže. Izlaz ANFISA sastoji se od sume izlaza neurona 4. sloja i definiran je sa funkcijom:

$$o_k = \frac{\sum_{i=1}^m w_i z_i}{\sum_{i=1}^m w_i},$$

2 Gradijenti spust - postupak učenja

Zadatak je naučiti hibridnu mrežu ANFIS kako bi računala funkciju:

$$f(x, y) = ((x - 1)^2 + (y + 2)^2 - 5xy + 3) \cdot \cos^2\left(\frac{x}{5}\right), x \in [-4, 4], y \in [-4, 4].$$

Definiramo kvadratnu pogrešku mreže za k -ti ulazni primjerak gdje je primjerak sastavljen od trojke (x_{1k}, x_{2k}, y_k) :

$$E_k = \frac{1}{2}(y_k - o_k)^2 \quad (3)$$

Učenje tj. optimiranje mreže provodimo gradijentnim spustom. Opća formula gradijentnog spusta gdje optimiramo parametar ψ o kojem greška ovisi je:

$$\psi(t + 1) = \psi(t) - \eta \frac{\partial E_k}{\partial \psi} \quad (4)$$

U našoj mreži s 2 ulaza i 1 izlazom parametri o kojima ovisi greška E_k su: $a_i, b_i, c_i, d_i, p_i, q_i$ i r_i . Moramo izračunati 7 parcijalnih derivacija funkcije E_k u ovisnosti ovim parametrima. To su parcijalne derivacije:

$$\frac{\partial E_k}{\partial a_i}, \frac{\partial E_k}{\partial b_i}, \frac{\partial E_k}{\partial c_i}, \frac{\partial E_k}{\partial d_i}, \frac{\partial E_k}{\partial p_i}, \frac{\partial E_k}{\partial q_i}, \frac{\partial E_k}{\partial r_i}$$

Za izvod svake parcijalne derivacije koristimo pravilo ulančavanja. Npr. za izračun parcijalne derivacije za parametar a_i koristimo lanac:

$$E_k \rightarrow o_k \rightarrow w_i \rightarrow \alpha_i \rightarrow a_i$$

odnosno:

$$\frac{\partial E_k}{\partial a_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial w_i} \cdot \frac{\partial w_i}{\partial \alpha_i} \cdot \frac{\partial \alpha_i}{\partial a_i} \quad (5)$$

Analogno i za sve ostale parametre mreže:

$$\frac{\partial E_k}{\partial b_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial w_i} \cdot \frac{\partial w_i}{\partial \alpha_i} \cdot \frac{\partial \alpha_i}{\partial b_i} \quad (6)$$

$$\frac{\partial E_k}{\partial c_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial w_i} \cdot \frac{\partial w_i}{\partial \beta_i} \cdot \frac{\partial \beta_i}{\partial c_i} \quad (7)$$

$$\frac{\partial E_k}{\partial d_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial w_i} \cdot \frac{\partial w_i}{\partial \beta_i} \cdot \frac{\partial \beta_i}{\partial d_i} \quad (8)$$

$$\frac{\partial E_k}{\partial p_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial z_i} \cdot \frac{\partial z_i}{\partial p_i} \quad (9)$$

$$\frac{\partial E_k}{\partial q_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial z_i} \cdot \frac{\partial z_i}{\partial q_i} \quad (10)$$

$$\frac{\partial E_k}{\partial r_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial z_i} \cdot \frac{\partial z_i}{\partial r_i} \quad (11)$$

Možemo uočiti da se mnogi članovi često ponavljaju što olakšava implementaciju jer ih ne moramo višestruko računati nego jednom za svaki ulazni uzorak k . Članovi parcijalnih derivacija koji se ponavljaju su: $\frac{\partial E_k}{\partial o_k}, \frac{\partial o_k}{\partial w_i}, \frac{\partial o_k}{\partial z_i}, \frac{\partial w_i}{\partial \alpha_i}$ i $\frac{\partial w_i}{\partial \beta_i}$

Izračun parcijalne derivacije: $\frac{\partial \mathbf{E}_k}{\partial \mathbf{o}_k}$

$$\frac{\partial E_k}{\partial o_k} = \frac{\partial}{\partial o_k} \left(\frac{1}{2} (y_k - o_k)^2 \right) = -(y_k - o_k) \quad (12)$$

Izračun parcijalne derivacije: $\frac{\partial \mathbf{o}_k}{\partial \mathbf{w}_i}$

$$\begin{aligned} \frac{\partial o_k}{\partial w_i} &= \frac{\partial}{\partial w_i} \left(\frac{\sum_{j=1}^m w_j z_j}{\sum_{j=1}^m w_j} \right) \\ &= \frac{\partial}{\partial w_i} \left(\frac{w_1 z_1 + w_2 z_2 + \dots + w_i z_i + \dots + w_m z_m}{\sum_{j=1}^m w_j} \right) \end{aligned}$$

Koristimo pravilo za derivaciju razlomka...

$$= \frac{\partial}{\partial w_i} \left(\frac{w_1 z_1}{\sum_{j=1}^m w_j} \right) + \dots + \frac{\partial}{\partial w_i} \left(\frac{w_i z_i}{\sum_{j=1}^m w_j} \right) + \dots + \frac{\partial}{\partial w_i} \left(\frac{w_m z_m}{\sum_{j=1}^m w_j} \right) \quad (13)$$

$$= \frac{-w_1 z_1}{(\sum_{j=1}^m w_j)^2} + \dots + \frac{z_i \sum_{j=1}^m w_j + w_i z_i}{(\sum_{j=1}^m w_j)^2} + \dots + \frac{-w_m z_m}{(\sum_{j=1}^m w_j)^2} \quad (14)$$

$$= \frac{-w_1 z_1}{(\sum_{j=1}^m w_j)^2} + \dots + \frac{-w_i z_i}{(\sum_{j=1}^m w_j)^2} + \dots + \frac{-w_m z_m}{(\sum_{j=1}^m w_j)^2} + \frac{z_i \sum_{j=1}^m w_j}{(\sum_{j=1}^m w_j)^2} \quad (15)$$

$$\frac{\partial o_k}{\partial w_i} = \frac{\sum_{j=1}^m w_j \cdot (z_i - z_j)}{(\sum_{j=1}^m w_j)^2} \quad (16)$$

Izračun parcijalne derivacije $\frac{\partial \mathbf{o}_k}{\partial \mathbf{z}_i}$

$$\frac{\partial o_k}{\partial z_i} = \frac{\partial}{\partial z_i} \left(\frac{\sum_{i=1}^m w_i z_i}{\sum_{i=1}^m w_i} \right)$$

$$\frac{\partial o_k}{\partial z_i} = \frac{w_i}{\sum_{j=1}^m w_j} \quad (17)$$

Izračun parcijalne derivacije $\frac{\partial \mathbf{w}_i}{\partial \beta_i}$ i $\frac{\partial \mathbf{w}_i}{\partial \alpha_i}$

$$\frac{\partial w_i}{\partial \beta_i} = \alpha_i$$

$$\frac{\partial w_i}{\partial \alpha_i} = \beta_i$$

Izračun parcijalne derivacije za parametre a_i , b_i , c_i te d_i

$$\frac{\partial E_k}{\partial a_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial w_i} \cdot \frac{\partial w_i}{\partial \alpha_i} \cdot \frac{\partial \alpha_i}{\partial a_i}$$

Prva tri člana u ovo izrazu smo već dobili iznad, potrebna nam je još parcijalna derivacija α_i po a_i .

$$\frac{\partial \alpha_i}{\partial a_i} = \frac{\partial}{\partial a_i} \left(\frac{1}{1 + e^{b_i(x-a_i)}} \right) = \frac{\partial \alpha_i}{\partial a_i} = \alpha_i \cdot (1 - \alpha_i) \cdot b_i$$

Izraz za ažuriranje parametra a_i konačno je:

$$a_i(t+1) = a_i(t) + \eta \cdot (y_k - o_k) \cdot \frac{\sum_{j=1}^m w_j \cdot (z_i - z_j)}{(\sum_{j=1}^m w_j)^2} \cdot \beta_i \cdot \alpha_i \cdot (1 - \alpha_i) \cdot b_i \quad (18)$$

$$\frac{\partial E_k}{\partial b_i} = \frac{\partial E_k}{\partial o_k} \cdot \frac{\partial o_k}{\partial w_i} \cdot \frac{\partial w_i}{\partial \alpha_i} \cdot \frac{\partial \alpha_i}{\partial b_i}$$

$$\frac{\partial \alpha_i}{\partial b_i} = \frac{\partial}{\partial b_i} \left(\frac{1}{1 + e^{b_i(x-a_i)}} \right) = \alpha_i \cdot (1 - \alpha_i) \cdot (x - a_i)$$

Izraz za ažuriranje parametra b_i konačno je:

$$b_i(t+1) = b_i(t) + \eta \cdot (y_k - o_k) \cdot \frac{\sum_{j=1}^m w_j \cdot (z_i - z_j)}{(\sum_{j=1}^m w_j)^2} \cdot \beta_i \cdot \alpha_i \cdot (1 - \alpha_i) \cdot (x - a_i) \quad (19)$$

Analogni postupak za parametre c_i i d_i

$$c_i(t+1) = c_i(t) + \eta \cdot (y_k - o_k) \cdot \frac{\sum_{j=1}^m w_j \cdot (z_i - z_j)}{(\sum_{j=1}^m w_j)^2} \cdot \alpha_i \cdot \beta_i \cdot (1 - \beta_i) \cdot d_i \quad (20)$$

$$d_i(t+1) = d_i(t) - \eta \cdot (y_k - o_k) \cdot \frac{\sum_{j=1}^m w_j \cdot (z_i - z_j)}{(\sum_{j=1}^m w_j)^2} \cdot \alpha_i \cdot \beta_i \cdot (1 - \beta_i) \cdot (x - c_i) \quad (21)$$

Izračun parcijalne derivacije za parametre p_i , q_i te r_i

Preostalo je još izračunati parcijalne derivacije po parametrima p_i , q_i te r_i . Za to su nam potrebne parcijalne derivacije $\frac{\partial z_i}{\partial p_i}$, $\frac{\partial z_i}{\partial q_i}$ i $\frac{\partial z_i}{\partial r_i}$

$$\frac{\partial z_i}{\partial p_i} = \frac{\partial}{\partial p_i} (p_i x + q_i y + r_i) = x$$

$$\frac{\partial z_i}{\partial q_i} = \frac{\partial}{\partial q_i} (p_i x + q_i y + r_i) = y$$

$$\frac{\partial z_i}{\partial r_i} = \frac{\partial}{\partial r_i} (p_i x + q_i y + r_i) = 1$$

Konačni izrazi za ažuriranje parametara p_i , q_i te r_i

$$p_i(t+1) = p_i(t) + \eta \cdot (y_k - o_k) \cdot \frac{w_i}{\sum_{j=1}^m w_j} \cdot x \quad (22)$$

$$q_i(t+1) = q_i(t) + \eta \cdot (y_k - o_k) \cdot \frac{w_i}{\sum_{j=1}^m w_j} \cdot y \quad (23)$$

$$r_i(t+1) = r_i(t) + \eta \cdot (y_k - o_k) \cdot \frac{w_i}{\sum_{j=1}^m w_j} \quad (24)$$

Učenje na cijelom skupu za učenje

Definiramo srednju kvadratnu pogrešku mreže za svih k ulaznih primjeraka gdje je primjerak sastavljen od para (x_{1k}, x_{2k}, y_k) a izlaz mreže o_k , a N broj primjeraka za učenje:

$$E = \frac{1}{2N} \sum_{k=1}^N (y_k - o_k)^2, \quad (25)$$

Moramo odrediti kako se mijenja pogreška E u ovisnosti o izlazu mreže o

$$\begin{aligned} \frac{\partial E}{\partial o} &= \frac{\partial}{\partial o_k} \left(\frac{1}{2N} \sum_{k=1}^N (y_k - o_k)^2 \right) \\ &= \frac{1}{2N} \sum_{k=1}^N \left(\frac{\partial}{\partial o_k} (y_k - o_k)^2 \right) \\ &= \frac{1}{2N} \sum_{k=1}^N (-2(y_k - o_k)) \\ &= -\frac{1}{N} \sum_{k=1}^N (y_k - o_k) \end{aligned}$$

Ostali članovi parcijalnih derivacija u lancu se ni za jedan parametar ne mjenjaju. Moramo u prethodno izvedenim izrazima (18) - (24) promjeniti samo član $\frac{\partial E_k}{\partial o_k}$ sa novoizvedenim $\frac{\partial E}{\partial o}$

$$a_i(t+1) = a_i(t) + \eta \cdot \frac{1}{N} \sum_{k=1}^N (y_k - o_k) \cdot \frac{\sum_{j=1}^m w_j \cdot (z_i - z_j)}{(\sum_{j=1}^m w_j)^2} \cdot \beta_i \cdot \alpha_i \cdot (1 - \alpha_i) \cdot b_i \quad (26)$$

$$b_i(t+1) = b_i(t) - \eta \cdot \frac{1}{N} \sum_{k=1}^N (y_k - o_k) \cdot \frac{\sum_{j=1}^m w_j \cdot (z_i - z_j)}{(\sum_{j=1}^m w_j)^2} \cdot \beta_i \cdot \alpha_i \cdot (1 - \alpha_i) \cdot (x - a_i) \quad (27)$$

$$c_i(t+1) = c_i(t) + \eta \cdot \frac{1}{N} \sum_{k=1}^N (y_k - o_k) \cdot \frac{\sum_{j=1}^m w_j \cdot (z_i - z_j)}{(\sum_{j=1}^m w_j)^2} \cdot \alpha_i \cdot \beta_i \cdot (1 - \beta_i) \cdot d_i \quad (28)$$

$$d_i(t+1) = d_i(t) - \eta \cdot \frac{1}{N} \sum_{k=1}^N (y_k - o_k) \cdot \frac{\sum_{j=1}^m w_j \cdot (z_i - z_j)}{(\sum_{j=1}^m w_j)^2} \cdot \alpha_i \cdot \beta_i \cdot (1 - \beta_i) \cdot (x - c_i) \quad (29)$$

$$p_i(t+1) = p_i(t) + \eta \cdot \frac{1}{N} \sum_{k=1}^N (y_k - o_k) \cdot \frac{w_i}{\sum_{j=1}^m w_j} \cdot x \quad (30)$$

$$q_i(t+1) = q_i(t) + \eta \cdot \frac{1}{N} \sum_{k=1}^N (y_k - o_k) \cdot \frac{w_i}{\sum_{j=1}^m w_j} \cdot y \quad (31)$$

$$r_i(t+1) = r_i(t) + \eta \cdot \frac{1}{N} \sum_{k=1}^N (y_k - o_k) \cdot \frac{w_i}{\sum_{j=1}^m w_j} \quad (32)$$

3 Učenje parametara

Funkcija 2 koju učimo je definiran prikazana je na slici:




Figure 2: Prikaz funkcije u domeni $[-4, 4] \times [-4, 4]$

Učenje s 1 pravilom

GD (engl. Gradient Descent) - normalni gradijentni algoritam

SGD (engl. Stochastic Gradient Descent) - stohastički gradijentni algoritam

GD




Figure 3: GD Prikaz naučene funkcije za sustav s 1 pravilom

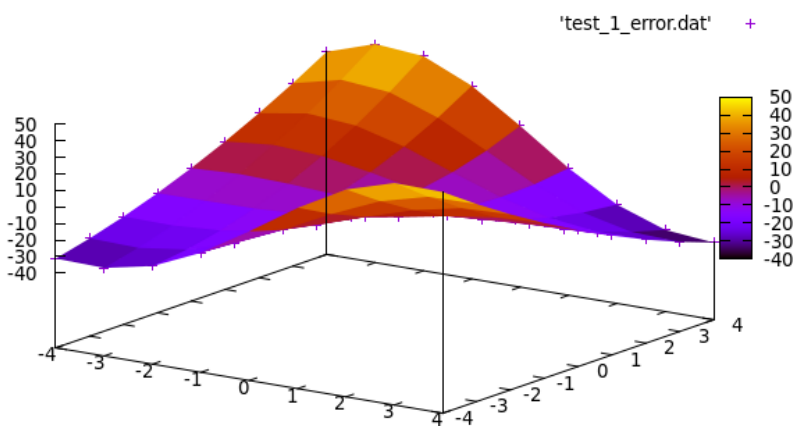


Figure 4: GD Prikaz funkcije pogreške za sustav s 1 pravilom

SGD




Figure 5: SGD Prikaz naučene funkcije za sustav s 1 pravilom




Figure 6: SGD Prikaz funkcije pogreške za sustav s 1 pravilom

Učenje s 2 pravila

GD




Figure 7: GD Prikaz naučene funkcije za sustav s 2 pravila




Figure 8: GD Prikaz funkcije pogreške za sustav s 2 pravila

SGD




Figure 9: SGD Prikaz naučene funkcije za sustav s 2 pravila




Figure 10: SGD Prikaz funkcije pogreške za sustav s 2 pravila

Učenje s 5 pravila

GD

$\eta_1 : 0.0007$, $\eta_2 : 0.01$, $error : 0.08709604459612692$




Figure 11: GD Prikaz naučene funkcije za sustav s 5 pravila

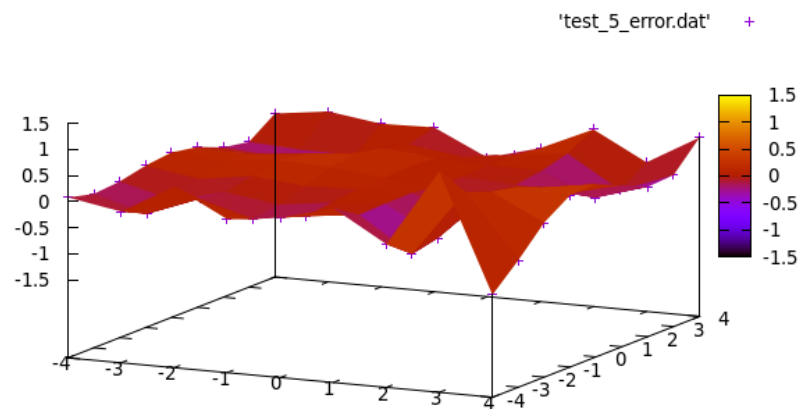


Figure 12: GD Prikaz funkcije pogreške za sustav s 5 pravila

SGD

$\eta_1 : 0.0007, \eta_2 : 0.01, error : 0.030076224714011102$




Figure 13: SGD Prikaz naučene funkcije za sustav s 5 pravila




Figure 14: SGD Prikaz funkcije pogreške za sustav s 5 pravila

Grafovi funkcija pripadnosti naučenog sustava




Figure 15: GD Prikaz funkcija pripadnosti




Figure 16: SGD Prikaz funkcija pripadnosti

Kretanje pogreške u ovisnosti o broju epoha

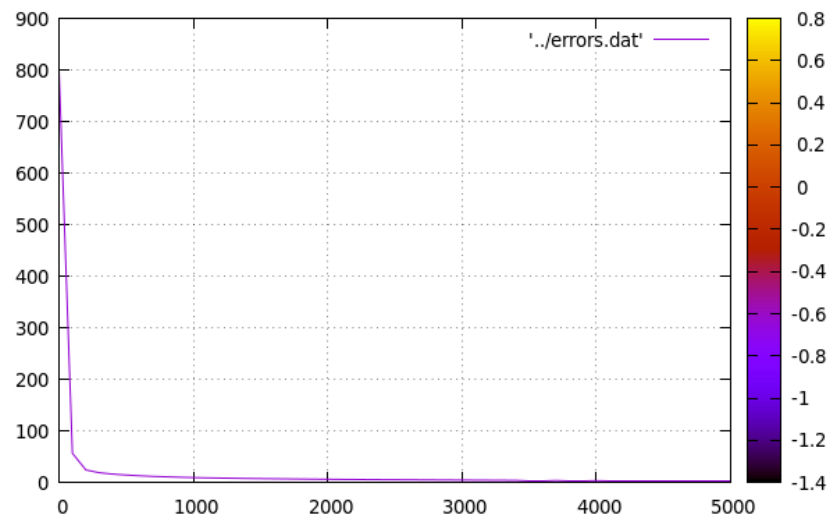


Figure 17: GD

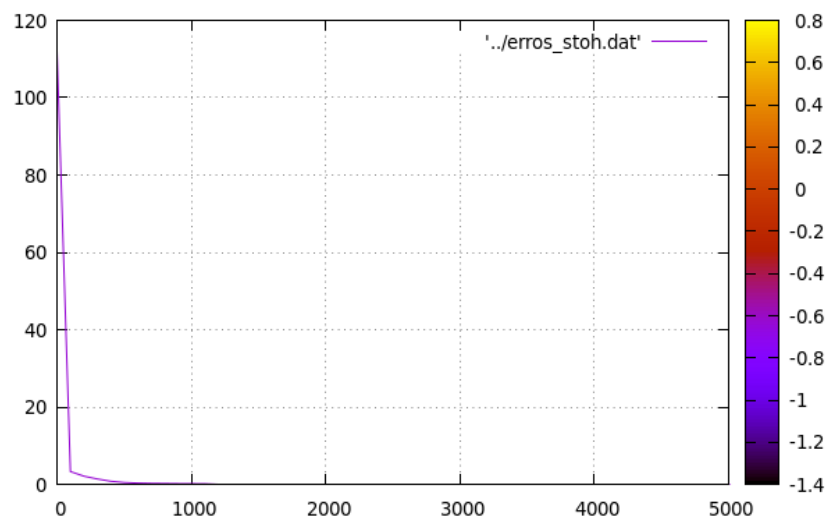


Figure 18: SGD

Kretanje pogreške u ovisnosti o broju epoha za rubne vrijednosti stope učenja

Promjena parametara a_i , b_i , c_i te d_i znatno utječe na strmost sigmoidalne funkcije pa zbog toga te parametre učimo sa stopom učenja manjom (η_1) nego za parametre izlaza (η_2).

Za prevelike stope učenja sustav divergira.

Primjer: GD: $\eta_1 : 0.5$, $\eta_2 : 0.7$, *error : error : 6.158311311006211e + 51*

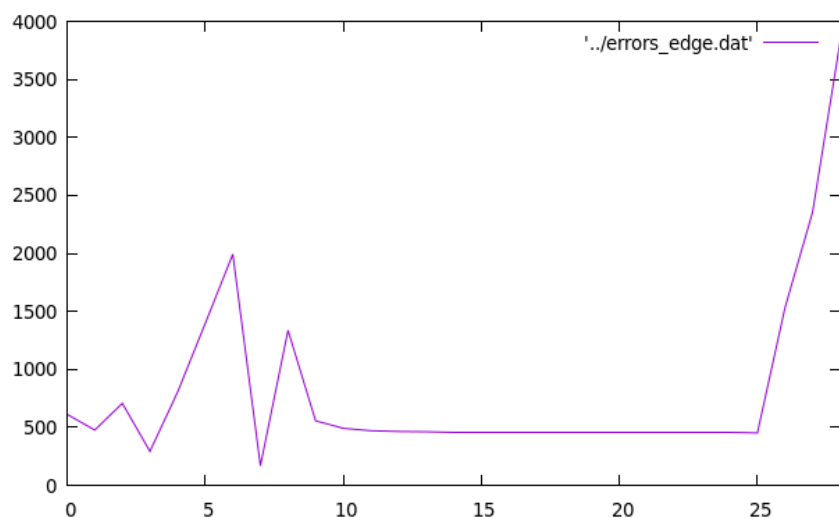


Figure 19: GD Prikaz greške za prevelike stope učenja, domena $[0, 30]$

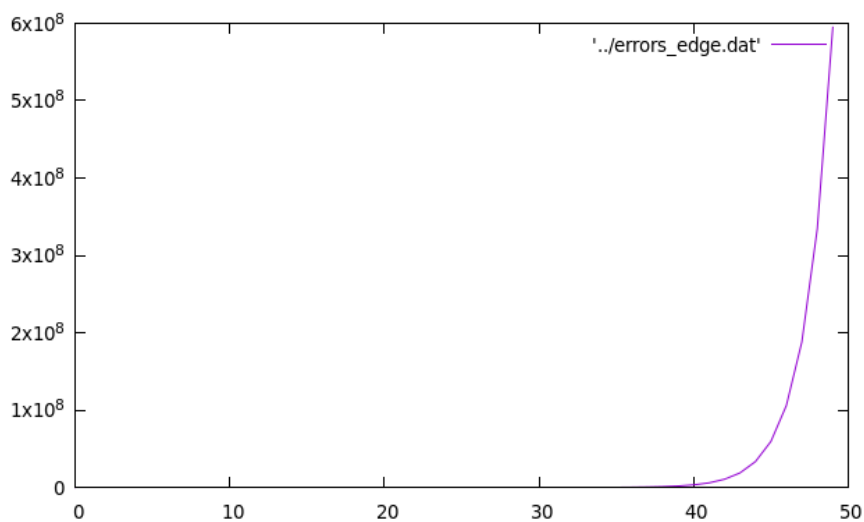


Figure 20: GD Prikaz greške za prevelike stope učenja, domena $[0, 50]$

Primjer: SGD: $\eta_1 : 0.06$, $\eta_2 : 0.17$, *error* : *error* : $6.158311311006211e + 51$




Figure 21: SGD Divergencija ukupne greške

Za premale stope učenja sustav jako sporo konvergira. Primjer: SGD: $\eta_1 : 0.00000000001$, $\eta_2 : 0.000007$, $error : error : 6.158311311006211e + 51$

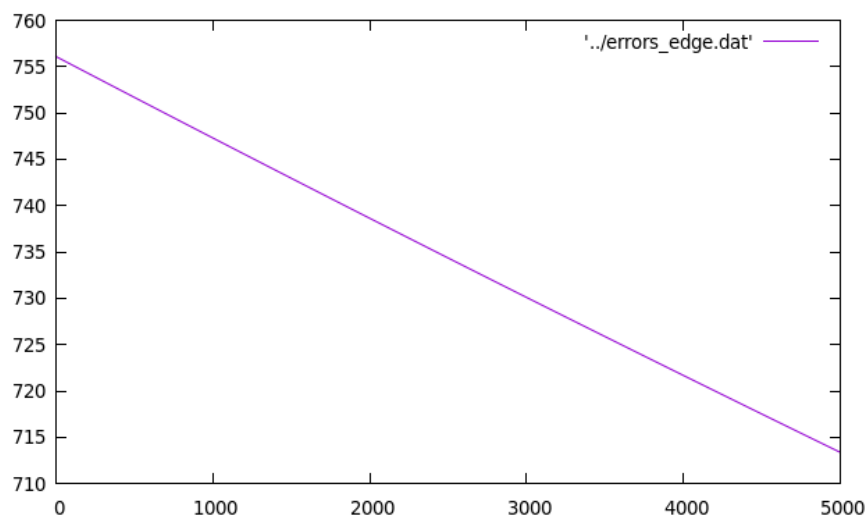


Figure 22: GD Prikaz konvergencije greške za jako male stope učenja




Figure 23: SGD Prikaz konvergencije greške za jako male stop učenja